

汇智海洋——设备检修知识检索与作业系统·软件开发设计文档

文档版本：V1.0 | 编制日期：2026-06-18 | 适用软件版本：V0.1.0+

编制单位：汇智海洋项目组

目录

- 1 项目概述
 - 1.1 编写目的
 - 1.2 项目背景
 - 1.3 行业痛点与解决方案
 - 1.4 可行性分析
 - 1.5 技术选型
 - 1.6 缩写与术语
- 2 需求分析
 - 2.1 目标用户
 - 2.2 业务需求
 - 2.3 功能用例分析
- 3 系统设计
 - 3.1 系统架构设计
 - 3.2 功能模块设计
 - 3.3 数据库设计
 - 3.4 API 接口设计
 - 3.5 前端界面设计
- 4 核心技术实现
 - 4.1 RAG 检索增强生成链路
 - 4.2 大模型适配层设计
 - 4.3 向量数据库集成
 - 4.4 PDF 解析与图片描述
 - 4.5 审核流程设计
 - 4.6 AI 反馈闭环设计
- 5 软件的法律与安全
 - 5.1 法律依据
 - 5.2 数据安全措施

1 项目概述

1.1 编写目的

本系统是基于多模态大模型技术构建的工业设备检修知识检索与作业辅助系统，以提高设备检修知识的检索效率、故障诊断的准确性和作业流程的标准化水平为目标。核心目标是通过大模型的语义理解与生成能力，结合

向量检索技术（RAG），实现设备手册、维修案例、操作规程等分散知识的智能化检索与问答，支持文本和图片的多模态输入，为一线检修人员提供精准的知识服务。

为明确系统在业务流程、技术实现、性能指标等方面的具体要求，为后续开发、测试及运维提供可落地的指导框架，特编写本文档。本文档将系统开发中的技术选型、功能规划及场景适配思路进行系统性梳理，为前后端开发、大模型集成、数据库设计提供功能边界与技术标准，确保各模块实现与需求对齐，定义功能验收指标作为开发阶段测试与迭代的基准。

1.2 项目背景

1.2.1 传统设备检修知识管理的挑战

工业设备检修是保障生产线稳定运行的关键环节。在传统的检修模式下，知识管理面临以下突出问题：

（1）知识分散难以检索

设备手册、维修规程、过往案例等知识散落在纸质文档、PDF文件、个人笔记等不同载体中。一线检修人员在面对故障时，往往需要在大量文档中翻阅查找，耗时费力且容易遗漏关键信息。

（2）经验传承依赖师徒制

大量宝贵的检修经验储存在资深技师脑中，通过口传心授的方式传承。当资深人员离职或退休时，这些经验知识也随之流失。新进人员缺乏快速获取经验的有效途径，成长周期长。

（3）作业流程缺乏标准化

不同班组、不同人员面对同类故障时，处理流程和操作标准不一致。缺乏统一的作业指引可能导致关键步骤遗漏，影响检修质量和设备安全。

（4）故障诊断依赖个人能力

面对复杂故障时，一线人员需凭借个人知识和经验进行诊断。在缺乏有效知识支撑的情况下，容易出现误判和重复操作，延长停机时间。

1.2.2 政策与行业驱动

国家大力推进工业互联网和智能制造战略，《“十四五”智能制造发展规划》明确提出推动人工智能在工业领域的深度应用。设备检修作为工业运维的核心环节，其数字化、智能化转型是实现智能制造的重要基础。在此背景下，将大模型、向量检索等AI技术应用于设备检修知识管理，成为提升工业运维效率的关键路径。

1.3 行业痛点与解决方案

1.3.1 行业痛点

（1）知识检索效率低下

一线检修人员在故障现场需要快速获取相关知识，但传统的关键词搜索匹配精度差，无法理解用户的自然语言描述，更无法根据故障现象的语义相似度检索历史案例。

（2）纸质手册数字化程度低

大量设备手册为PDF格式，其中的图片、表格等非文本内容难以被传统搜索引擎索引。人工提取和标注图片内容工作量大、效率低。

（3）隐性经验难以沉淀

检修人员的个人经验（如“某种异响通常是XX故障的前兆”）缺乏便捷的提交和审核机制，难以形成组织级的知识资产。

（4）AI辅助手段不足

传统检修辅助工具多为固定问答库，无法理解复杂的故障描述，更不能结合图片进行视觉分析。一线人员急需能理解自然语言、能看图分析、能给出结构化诊断建议的智能助手。

1.3.2 系统解决方案

（1）智能语义检索

基于ChromaDB向量数据库和千问Embedding模型，将知识内容向量化后进行语义级别检索。用户以自然语言描述故障现象，系统自动匹配最相关的知识条目，准确率远高于关键词匹配。

（2）PDF自动解析与图片描述

使用PyMuPDF（fitz）提取PDF全文和嵌入图片，调用千问VL视觉大模型自动生成图片的中文描述，使图片内容可被检索。

（3）案例上传与两级审核

一线人员可便捷提交检修案例（含现场图片），经过管理员初审和专家复审两级审核后纳入知识库，形成经验沉淀闭环。

（4）RAG智能对话

采用检索增强生成（RAG）技术，将知识检索结果作为大模型的上下文，生成结构化的故障诊断建议（分析→原因→方案→来源），确保回答基于实际知识而非模型幻觉。

（5）标准化作业指引

管理员预设检修流程模板，一线人员按步骤执行任务。每步包含操作说明和合规校验项，确保关键步骤不遗漏。系统自动根据设备型号和检修等级匹配最佳模板。

1.4 可行性分析

1.4.1 技术可行性

系统采用成熟的开源技术栈：后端为FastAPI（Python），前端为Vue 3，向量数据库为ChromaDB，大模型API使用DeepSeek和千问。以上技术均具备活跃的社区支持和丰富的文档资源。系统不依赖特定硬件（GPU等），大模型通过云端API调用，降低了本地部署的技术门槛。

1.4.2 经济可行性

系统开发以开源技术为主，无商业软件许可费用。运行成本主要为大模型API调用费用：DeepSeek约¥0.001/千tokens，千问VL约¥0.003/千tokens，Embedding约¥0.0007/千tokens，按中等使用频率估算月成本控制在数百

元级别。相比传统人工检索和咨询模式，可显著节省人力成本。

1.4.3 操作可行性

系统采用B/S架构，用户通过浏览器访问，无需安装客户端。界面设计遵循直观简洁原则，用户端导航清晰（首页→AI助手→作业指引→案例上传→客服工单→个人工作台），一线人员可快速上手。管理端功能模块通过侧边栏分类组织，管理员可通过仪表盘快速定位待处理事项。

1.4.4 法律可行性

系统开发与运营严格遵守国家相关法律法规。在数据安全方面，遵循《网络安全法》《数据安全法》《个人信息保护法》的规定，用户密码采用bcrypt哈希存储，API通信使用JWT令牌认证。在知识产权方面，用户上传内容的知识产权归用户所有，系统仅提供平台服务。

1.5 技术选型

层级	技术	版本	选型理由
前端框架	Vue 3 (Composition API)	3.5.x	响应式数据绑定、组件化开发、生态成熟
构建工具	Vite	5.4.x	极速冷启动、HMR热更新
UI组件库	Element Plus	2.8.x	企业级Vue 3组件库，中文文档完善
后端框架	FastAPI	0.115	高性能异步框架、自动生成API文档、类型安全
ASGI服务器	Uvicorn	0.30	支持异步、高性能
ORM	SQLAlchemy	2.0	异步支持、成熟稳定
数据库	SQLite (开发) / PostgreSQL (生产)	—	SQLite零配置、PG支持高并发
异步SQLite驱动	aiosqlite	0.20	适配FastAPI异步模型
向量数据库	ChromaDB	0.5	嵌入运行、Python原生、支持多Embedding
LLM编排	LangChain	0.3	大模型调用抽象、RAG链路编排
PDF解析	PyMuPDF (fitz)	1.24	解析精度高、支持图片提取
图像处理	Pillow	10.4	Python标准图像库
认证	python-jose (JWT) + passlib (bcrypt)	—	行业标准认证方案
HTTP客户端	httpx	0.27	异步HTTP客户端，用于调用LLM API
容器化	Docker + Docker Compose	—	环境一致性、一键部署

1.6 缩写与术语

缩写/术语	全称或定义
LLM	Large Language Model（大语言模型），用于文本生成和图文理解
RAG	Retrieval-Augmented Generation（检索增强生成），检索+生成的AI回答模式
VL	Vision-Language（视觉-语言），指能理解和分析图片的多模态模型
Embedding	嵌入向量，将文本转换为数学向量表示的技术
ChromaDB	开源向量数据库，存储和检索向量化的知识内容
WAL	Write-Ahead Logging，SQLite的预写日志模式，提升并发性能
JWT	JSON Web Token，基于JSON的认证令牌
B/S 架构	Browser/Server 架构，用户通过浏览器访问服务端
SSE	Server-Sent Events，服务端推送事件，用于流式传输AI回复
CRUD	Create, Read, Update, Delete（增删改查）基本数据操作
PDF	Portable Document Format（便携式文档格式）
ORC	Optical Character Recognition（光学字符识别）
LoongArch	龙芯自主指令集架构（loongarch64）

2 需求分析

2.1 目标用户

系统共有三类目标用户：

角色	标识	核心诉求
一线检修人员	worker	快速查找设备检修知识；获得AI故障诊断建议；按标准流程执行检修任务；提交经验案例
知识管理员	admin	管理知识库内容；审核用户提交的案例；管理用户账号；配置系统参数
技术专家	expert	复审经验型案例的技术准确性；回复专业工单；提供权威技术指导

2.2 业务需求

2.2.1 用户端业务需求

一线人员需要一个集知识检索、AI问答、作业执行、经验提交于一体的综合工作平台：

1. **知识浏览与检索**：按设备型号、故障标签分类浏览；支持自然语言关键词搜索和语义检索
2. **AI智能对话**：支持文本和图片多模态输入；检修模式下给出结构化诊断建议；可对回答质量进行反馈
3. **标准化作业执行**：按模板创建任务；逐步执行并确认合规项；支持暂停/恢复/交接
4. **案例提交与追踪**：提交检修案例（含图片）；追踪审核进度
5. **客服工单**：提交问题工单；查看回复并确认解决

2.2.2 管理端业务需求

管理员和专家需要一个统一的管理后台来维护系统的正常运转：

- 1. **知识库管理**：新增/编辑/发布/归档/删除知识条目；PDF手册导入解析；版本历史管理
- 2. **案例审核**：查看案例内容（含图片）；通过/驳回/修改后通过；两级审核（管理员初审+专家复审）
- 3. **用户反馈管理**：处理客服工单（回复/关闭/转知识条目）；查看AI反馈（有用/无用标注）并转知识
- 4. **用户管理**：审核通过新用户；启用/禁用账号；重置密码
- 5. **系统配置**：管理设备型号和故障标签；管理作业模板（含步骤编辑器）；动态配置大模型API

2.3 功能用例分析

2.3.1 用户管理模块

用例名称	参与者	用例描述
用户注册	一线人员	填写用户名、姓名、密码等信息完成注册，等待管理员审核
用户登录	所有用户	通过用户名密码校验身份，获取JWT令牌
退出登录	所有用户	结束当前会话，清除本地令牌
审核用户	管理员	审核通过待审核状态的用户
启用/禁用用户	管理员	控制用户账号的可用状态
重置密码	管理员	为用户重置登录密码

2.3.2 知识检索模块

用例名称	参与者	用例描述
分类浏览	所有用户	按设备型号和故障标签分类浏览知识条目
关键词搜索	所有用户	输入关键词按标题和摘要模糊匹配
排序切换	所有用户	按最新发布或最热（浏览次数）排序
查看详情	所有用户	查看知识条目完整内容、图片、原始PDF
语义检索	所有用户	通过自然语言描述进行语义级别检索

2.3.3 AI对话模块

用例名称	参与者	用例描述
检修模式对话	所有用户	RAG模式：检索知识+大模型生成结构化诊断建议
闲聊模式对话	所有用户	直接与大模型进行自然语言对话
图片分析	所有用户	上传故障图片，调用千问VL进行视觉分析
对话管理	所有用户	创建/切换/重命名/删除对话
反馈AI回复	所有用户	对AI回复标记有用/部分有用/无用，可填写修正建议

2.3.4 作业指引模块

用例名称	参与者	用例描述
创建任务	所有用户	选择设备型号和检修等级，匹配模板后创建任务
执行步骤	所有用户	按步骤执行检修作业，勾选合规项后推进
暂停/恢复	所有用户	暂停任务（填写原因）或恢复执行
交接任务	所有用户	将任务移交给其他人员
提前完成	所有用户	在未执行完所有步骤时强制完成任务

2.3.5 案例上传与审核模块

用例名称	参与者	用例描述
提交案例	所有用户	填写案例信息，上传现场图片，提交审核
初审	管理员	审查案例格式和事实准确性，通过/驳回/修改后通过
复审	专家	对经验型案例进行技术准确性验证
入库	系统自动	审核通过后创建知识条目+向量化

2.3.6 客服工单模块

用例名称	参与者	用例描述
提交工单	所有用户	填写问题标题和描述，提交工单
回复工单	管理员/专家	查看问题并给予回复
确认解决	所有用户	确认问题已解决
转知识条目	管理员/专家	将已解决的工单转化为知识草稿

2.3.7 系统管理模块


用例名称	参与者	用例描述
知识条目管理	管理员	新增/编辑/发布/归档/删除（CRUD）
PDF导入	管理员	上传PDF文件，自动解析+向量化
版本管理	管理员	查看历史版本，支持回滚
设备/标签管理	管理员	管理设备型号字典和故障标签字典
模板管理	管理员	创建和编辑检修流程模板（含步骤编辑器）
模型配置	管理员	动态配置大模型API Key和参数
操作日志	管理员	查看系统关键操作的审计记录


用例名称	参与者	用例描述
数据备份	管理员	手动或自动备份数据库和文件

3 系统设计

3.1 系统架构设计

系统采用前后端分离的B/S三层架构：表现层（Vue 3前端）、业务逻辑层（FastAPI后端）、数据层（SQLite/PostgreSQL + ChromaDB + 文件系统）。





3.2 功能模块设计

系统功能模块分为用户端五大模块和管理端八大模块：

编号	模块名称	归属	功能概述
1	首页/知识检索	用户端	分类导航、关键词搜索、排序、知识卡片、悬浮AI
2	AI智能助手	用户端	RAG检修对话、闲聊对话、图片分析、对话管理、反馈
3	作业指引	用户端	任务列表、模板匹配、步骤执行、暂停/交接/完成
4	案例上传	用户端	填写案例、上传图片、提交审核、保存草稿
5	客服工单	用户端	提交工单、查看回复、确认解决
6	个人工作台	用户端	我的任务、上传、工单、AI反馈修正记录聚合
7	仪表盘	管理端	统计概览、快捷入口、最近日志
8	知识库管理	管理端	条目CRUD、PDF导入、版本管理、发布/归档
9	审核队列	管理端	案例查看、通过/驳回/修改后通过、两级审核
10	用户反馈管理	管理端	工单回复/转知识、AI反馈查看/转知识

编号	模块名称	归属	功能概述
11	用户管理	管理端	审核用户、启用/禁用、重置密码、删除
12	设备/模板管理	管理端	设备型号字典、故障标签字典、作业模板(含步骤编辑器)
13	模型配置	管理端	大模型API动态配置、测试连通性、激活切换
14	操作日志/系统设置	管理端	审计日志查看、数据备份、系统信息

3.3 数据库设计

3.3.1 实体关系图（ER图）概述

系统数据库包含以下核心实体及其关系：



3.3.2 核心数据表设计

表：users（用户表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	用户ID
username	VARCHAR(50)	UNIQUE, NOT NULL	用户名
hashed_password	VARCHAR(200)	NOT NULL	bcrypt密码哈希
name	VARCHAR(50)	NOT NULL	真实姓名
employee_id	VARCHAR(50)	—	工号
team	VARCHAR(100)	—	所属班组
role	VARCHAR(20)	NOT NULL	角色：worker/admin/expert

字段标识	字段类型	约束	字段名称
status	VARCHAR(20)	NOT NULL	状态：pending/active/disabled
created_at	DATETIME	—	创建时间

表：knowledge_entries（知识条目表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	条目ID
title	VARCHAR(300)	NOT NULL, INDEX	知识标题
content	TEXT	NOT NULL	正文内容（富文本）
summary	TEXT	—	摘要
source	VARCHAR(11)	NOT NULL	来源： manual/pdf_import/user_upload/ticket/ai_feedback
source_ref	VARCHAR(300)	—	来源引用
device_models	JSON	—	关联设备型号列表
fault_tags	JSON	—	故障分类标签列表
maintenance_level	VARCHAR(20)	—	检修等级
is_procedure	BOOLEAN	—	是否作业指引类型
status	VARCHAR(9)	NOT NULL	状态：draft/published/archived
current_version	VARCHAR(20)	—	当前版本号
view_count	INTEGER	DEFAULT 0	浏览次数
author_id	INTEGER	FK→users.id	创建者ID
created_at	DATETIME	—	创建时间
updated_at	DATETIME	—	更新时间

表：knowledge_versions（知识版本表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	版本ID
entry_id	INTEGER	FK→knowledge_entries.id, NOT NULL	所属条目ID
version	VARCHAR(20)	NOT NULL	版本号字符串
version_num	INTEGER	NOT NULL	版本序号（排序用）
content	TEXT	NOT NULL	该版本完整内容快照

字段标识	字段类型	约束	字段名称
change_summary	VARCHAR(500)	—	修改说明
editor_id	INTEGER	FK→users.id	编辑者ID
created_at	DATETIME	—	创建时间

表：conversations（对话会话表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	会话ID
user_id	INTEGER	FK→users.id, NOT NULL, INDEX	所属用户ID
title	VARCHAR(200)	—	会话标题
context_device_model	VARCHAR(100)	—	关联设备型号
context_task_step	VARCHAR(200)	—	关联作业步骤
created_at	DATETIME	—	创建时间
updated_at	DATETIME	—	更新时间

表：messages（对话消息表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	消息ID
conversation_id	INTEGER	FK→conversations.id, NOT NULL	所属会话ID
role	VARCHAR(20)	NOT NULL	角色：user/assistant
content	TEXT	NOT NULL	消息内容
structured_reply	JSON	—	AI结构化回复数据
feedback	VARCHAR(20)	—	用户反馈： useful/partial/useless
feedback_comment	TEXT	—	用户修正建议
image_urls	JSON	—	图片路径列表
created_at	DATETIME	—	创建时间

表：case_uploads（案例上传表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	案例ID
title	VARCHAR(300)	NOT NULL	案例标题

字段标识	字段类型	约束	字段名称
content	TEXT	NOT NULL	案例正文
device_models	JSON	—	设备型号
fault_tags	JSON	—	故障标签
is_experience_based	BOOLEAN	—	是否经验型
images	JSON	—	图片路径列表
review_status	VARCHAR(20)	NOT NULL	审核状态
review_comment	TEXT	—	审核意见
reject_reason	VARCHAR(500)	—	驳回原因
uploader_id	INTEGER	FK→users.id	上传者ID
linked_entry_id	INTEGER	FK→knowledge_entries.id	关联知识条目ID
created_at	DATETIME	—	创建时间

表：tickets（客服工单表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	工单ID
ticket_no	VARCHAR(30)	UNIQUE, NOT NULL	工单号（TK-YYYYMMDD-NNNN）
title	VARCHAR(300)	NOT NULL	问题标题
description	TEXT	NOT NULL	问题描述
images	JSON	—	图片列表
creator_id	INTEGER	FK→users.id, NOT NULL	提交人ID
assignee_id	INTEGER	FK→users.id	处理人ID
status	VARCHAR(20)	NOT NULL	状态： pending/processing/replied/resolved/closed
created_at	DATETIME	—	创建时间
updated_at	DATETIME	—	更新时间

表：ticket_replies（工单回复表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	回复ID
ticket_id	INTEGER	FK→tickets.id, NOT NULL	所属工单ID

字段标识	字段类型	约束	字段名称
replier_id	INTEGER	FK→users.id, NOT NULL	回复人ID
content	TEXT	NOT NULL	回复内容
attachments	JSON	—	附件列表
created_at	DATETIME	—	创建时间

表：task_records（任务记录表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	任务ID
title	VARCHAR(300)	NOT NULL	任务名称
device_model	VARCHAR(100)	NOT NULL	设备型号
maintenance_level	VARCHAR(20)	NOT NULL	检修等级
template_id	INTEGER	—	使用的模板ID
assignee_id	INTEGER	FK→users.id, NOT NULL	当前执行人ID
status	VARCHAR(20)	—	状态：in_progress/paused/completed
current_step	INTEGER	—	当前步骤编号
total_steps	INTEGER	—	总步骤数
confirmed_steps	JSON	—	已确认步骤列表
handover_chain	JSON	—	交接链记录
started_at	DATETIME	—	开始时间
completed_at	DATETIME	—	完成时间

表：procedure_templates（作业模板表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	模板ID
name	VARCHAR(200)	NOT NULL	模板名称
device_models	JSON	—	适用设备型号
maintenance_level	VARCHAR(20)	NOT NULL	检修等级
steps	JSON	—	步骤列表（含 phase/title/content/compliance_items）
version	VARCHAR(20)	—	版本号
status	VARCHAR(20)	—	状态：draft/published/archived

字段标识	字段类型	约束	字段名称
author_id	INTEGER	FK→users.id	创建者ID
created_at	DATETIME	—	创建时间

表：audit_logs（审计日志表）

字段标识	字段类型	约束	字段名称
id	INTEGER	PK, AUTO	日志ID
user_id	INTEGER	FK→users.id	操作人ID
action	VARCHAR(100)	NOT NULL	操作类型
target_type	VARCHAR(50)	NOT NULL	操作对象类型
target_id	INTEGER	—	操作对象ID
detail	TEXT	—	操作详情
created_at	DATETIME	—	创建时间

3.4 API 接口设计

系统所有API以 `/api/v1/` 为版本前缀，采用 RESTful 风格设计。

3.4.1 认证模块（auth）

方法	路径	说明	权限
POST	/auth/register	用户注册	公开
POST	/auth/login	用户登录	公开
GET	/auth/me	获取当前用户信息	已登录
GET	/auth/users	用户列表	管理员
PUT	/auth/users/{id}/status	更新用户状态	管理员
POST	/auth/users/{id}/reset-password	重置密码	管理员
DELETE	/auth/users/{id}	删除用户	管理员
GET	/auth/logs	操作日志列表	管理员

3.4.2 知识库模块（knowledge）

方法	路径	说明	权限
GET	/knowledge/	知识条目列表（分页+筛选）	已登录
GET	/knowledge/tags	获取所有设备型号和故障标签	已登录

方法	路径	说明	权限
GET	/knowledge/{id}	知识条目详情	已登录
POST	/knowledge/	新增知识条目	管理员
PUT	/knowledge/{id}	编辑知识条目	管理员
POST	/knowledge/{id}/publish	发布草稿	管理员
PUT	/knowledge/{id}/archive	归档知识条目	管理员
DELETE	/knowledge/{id}	删除知识条目	管理员
GET	/knowledge/{id}/versions	版本历史列表	管理员
POST	/knowledge/{id}/versions/{v}/rollback	回滚到指定版本	管理员

3.4.3 AI对话模块（chat）

方法	路径	说明	权限
POST	/conversations	创建新对话	已登录
GET	/conversations	我的对话列表	已登录
GET	/conversations/my-feedback	我的AI反馈记录	已登录
GET	/conversations/{id}	对话详情（含消息）	已登录(属主)
DELETE	/conversations/{id}	删除对话	已登录(属主)
PUT	/conversations/{id}	重命名对话	已登录(属主)
POST	/chat	发送消息	已登录
POST	/conversations/{id}/feedback	提交AI反馈	已登录

3.4.4 审核与反馈管理模块

方法	路径	说明	权限
GET	/review/	审核队列列表	管理员/专家
GET	/review/{id}	审核详情	管理员/专家
POST	/review/{id}/action	执行审核操作	管理员/专家
GET	/admin/feedback	AI反馈汇总列表	管理员
POST	/admin/feedback/{id}/to-knowledge	AI反馈转知识	管理员
DELETE	/admin/feedback/{id}	删除AI反馈	管理员

3.4.5 作业指引模块（tasks）

方法	路径	说明	权限
GET	/tasks/	我的任务列表	已登录
POST	/tasks/	创建任务	已登录
GET	/tasks/{id}	任务详情	已登录
POST	/tasks/{id}/step	确认步骤	已登录
POST	/tasks/{id}/pause	暂停任务	已登录
POST	/tasks/{id}/resume	恢复任务	已登录
POST	/tasks/{id}/handover	交接任务	已登录
POST	/tasks/{id}/complete	提前完成	已登录
GET	/tasks/templates	模板列表	已登录
POST	/tasks/templates	创建模板	管理员
PUT	/tasks/templates/{id}	更新模板	管理员
DELETE	/tasks/templates/{id}	删除模板	管理员
POST	/tasks/templates/match	模板匹配	已登录

3.4.6 工单模块 (tickets)

方法	路径	说明	权限
GET	/tickets/	工单列表	已登录
POST	/tickets/	提交工单	已登录
GET	/tickets/{id}	工单详情	已登录
POST	/tickets/{id}/reply	回复工单	管理员/专家
PUT	/tickets/{id}/status	更新状态	已登录
POST	/tickets/{id}/to-knowledge	工单转知识	管理员/专家
DELETE	/tickets/{id}	删除工单	管理员/提交者

3.4.7 文件与配置模块

方法	路径	说明	权限
POST	/upload	上传文件	已登录
POST	/import/pdf	导入PDF	管理员
GET	/config/device-models	设备型号列表	已登录
POST	/config/device-models	新增设备	管理员

方法	路径	说明	权限
GET	/models/configs	模型配置列表	管理员
POST	/models/configs	新增模型配置	管理员
POST	/models/configs/{id}/activate	激活模型	管理员
POST	/models/configs/{id}/test	测试连通性	管理员

3.5 前端界面设计

3.5.1 界面设计原则

- **直观性**：用户端采用顶部导航+内容区布局，管理端采用侧边栏+内容区布局，功能入口明确
- **一致性**：所有页面统一使用Element Plus组件库，色彩、间距、字体保持一致
- **响应式**：PC Web端优先，适配平板设备
- **反馈清晰**：所有操作有明确的成功/失败提示，空状态有引导文字

3.5.2 页面路由设计

用户端路由（/ 根路径）：

路由	页面组件	说明
/	Home.vue	首页知识库浏览
/search	SearchResult.vue	搜索结果
/knowledge/:id	KnowledgeDetail.vue	知识详情
/chat	Chat.vue	AI全屏对话
/chat/:id	Chat.vue	AI对话（指定会话）
/task	TaskList.vue	任务列表
/task/:id	TaskExecute.vue	任务执行
/upload	CaseUpload.vue	案例上传
/tickets	TicketList.vue	工单列表
/tickets/:id	TicketDetail.vue	工单详情
/workspace	Workspace.vue	个人工作台

管理端路由（/admin 路径）：

路由	页面组件	说明
/admin	Dashboard.vue	仪表盘
/admin/knowledge	KnowledgeManage.vue	知识管理
/admin/knowledge/new	KnowledgeEdit.vue	新增知识

路由	页面组件	说明
/admin/knowledge/:id/edit	KnowledgeEdit.vue	编辑知识
/admin/review	ReviewQueue.vue	审核列表
/admin/review/:id	ReviewDetail.vue	审核详情
/admin/tickets	TicketManage.vue	工单管理
/admin/tickets/:id	TicketManageDetail.vue	工单管理详情
/admin/users	UserManage.vue	用户管理
/admin/devices	DeviceManage.vue	设备/标签管理
/admin/templates	TemplateManage.vue	模板管理
/admin/feedback	FeedbackManage.vue	AI反馈管理
/admin/model-config	ModelConfig.vue	模型配置
/admin/logs	AuditLogs.vue	操作日志
/admin/settings	SystemSettings.vue	系统设置

4 核心技术实现

4.1 RAG 检索增强生成链路

系统采用RAG（Retrieval-Augmented Generation）技术实现智能检修问答。其核心流程如下：






关键设计决策:

- **Top K 设为5:** 在检索精度和上下文长度间平衡, 避免过大上下文挤占生成空间
- **每条600字符截断:** 确保总上下文约3000字符, 为生成留足~5000 tokens
- **重试机制:** API调用最多重试3次, 90秒超时; 4xx错误不重试 (认证/参数错误); 5xx和网络错误重试
- **模式分离:** 闲聊模式跳过向量检索和结构化解析, 直接对话式回答

4.2 大模型适配层设计

系统通过ModelAdapter抽象基类和ModelRouter路由器实现多模型的统一调用和动态切换。

设计模式:



配置加载策略:

- 1. 启动时一次性加载: `ModelRouter.load_configs_sync()` 在 `lifespan` 中调用, 使用隔离的 `sqlite3.connect()` 读取 `model_configs` 表
- 2. 运行时零DB访问: 配置缓存在 `_db_cfg` 字典中, 避免与SQLAlchemy的写锁冲突
- 3. 自动类型识别: 根据模型名称关键词 (`deepseek/chat`→`text`, `qwen/vl`→`vision`, `embed/bge`→`embedding`) 自动归类
- 4. 配置切换: 管理员修改配置后调用 `invalidate_cache()` 清空缓存重新加载

4.3 向量数据库集成

使用ChromaDB作为向量数据库, 封装为 `ChromaVectorStore` 服务类。

Embedding提供者选择优先级:

- 1. 数据库配置的Embedding模型 (管理员在后台激活)
- 2. `.env` 中的 `EMBEDDING_PROVIDER=api` → 千问DashScope `text-embedding-v4` (推荐, 1024维, 中文最优)
- 3. `.env` 中的 `EMBEDDING_PROVIDER=local` → 本地 `BGE-Small-ZH` 模型 (离线可用, 需下载~100MB)
- 4. ChromaDB内置默认 `all-MiniLM-L6-v2` (兜底, 中文效果弱)

关键实现细节:

- 延迟初始化: Embedding函数在首次入库或检索时才加载, 避免启动阻塞
- 线程安全: 使用 `threading.Lock` 双重检查锁定确保多线程下单次初始化
- 零向量检测: Embedding调用失败时返回零向量 `[0.0]*1024`, 检索时可检测并处理
- 元数据过滤: 支持 `filter_metadata` 参数按设备型号等字段过滤检索结果

4.4 PDF 解析与图片描述

使用PyMuPDF (`fitz`) 作为PDF解析引擎, 集成千问VL视觉模型生成图片描述。

解析流程:






设计要点：

- 图片保存为PNG格式后上传到临时目录，调用千问VL分析
- 千问VL调用失败时图片chunk标记为占位，不阻塞整体导入
- PyMuPDF作为主力引擎，pdfplumber作为备选方案
- 导入的条目初始为草稿状态，需管理员确认后发布

4.5 审核流程设计

案例审核采用两级审核机制，根据知识类型走不同流程。




入库流程（通过后自动执行）：

1. 创建 `KnowledgeEntry` （来源=`user_upload`，状态=`published`）
2. 将案例中的图片URL嵌入content末尾（`<img>` 标签）
3. 创建初始版本 `KnowledgeVersion V1.0`
4. 提交数据库事务（释放写锁）
5. 调用 `vector_store.add_documents()` 向量化（在事务外，避免锁冲突）
6. 更新 `case.review_status = APPROVED`，关联 `linked_entry_id`

设计要点：第4步先commit再操作向量库是关键设计——在SQLite环境下，长事务（等待Embedding API 响应）会持锁导致其他请求阻塞。

4.6 AI 反馈闭环设计

系统设计了完整的"AI回答→用户反馈→管理员审查→知识改进"闭环。



连续无用提示：当用户在同一对话中连续两次标记"无用"时，系统提示建议提交客服工单获取人工帮助。

5 软件的法律与安全

5.1 法律依据

在软件设计与部署过程中，将相关法律法规纳入考量：

(1) 知识产权与版权法

- 用户上传的知识内容（案例、手册等）版权归原始权利人所有
- 系统作为平台工具，不对用户上传内容主张版权
- 通过大模型API生成的内容，其版权归属遵循API提供方的服务条款
- 系统源代码归项目组所有

(2) 数据隐私与个人信息保护

- 依据《中华人民共和国个人信息保护法》，系统仅收集业务必需的用户信息（用户名、姓名、工号、班组）
- 用户密码使用bcrypt单向哈希存储，不可逆
- 用户对话内容存储于数据库中，仅用户本人和管理员可查看
- 上传的图片文件存储在服务器本地，通过URL访问

(3) 网络安全法

- 依据《中华人民共和国网络安全法》，系统实施用户身份认证（JWT）
- 实施基于角色的访问控制（RBAC），三类角色权限隔离
- API通信可使用HTTPS加密（生产环境Nginx配置SSL证书）

5.2 数据安全措施

安全层面	措施
身份认证	JWT令牌 + bcrypt密码哈希；令牌8小时过期
访问控制	RBAC角色权限（worker/admin/expert）；路由守卫+后端依赖校验
数据加密	密码bcrypt哈希（不可逆）；生产环境HTTPS传输
API安全	所有数据操作验证用户归属（如只能访问自己的对话）；跨域CORS白名单
审计追溯	所有关键操作记录到audit_logs表（含操作人、时间、操作类型、详情）
数据备份	系统设置中支持手动+自动定期备份
SQL注入防护	使用SQLAlchemy ORM的参数化查询，杜绝拼接SQL

文档版本：V1.0 | 编制日期：2026-06-18 | 编制人：汇智海洋项目组

© 2026 汇智海洋 · 设备检修知识检索与作业系统